Chào bạn, đây là bản **GUIDELINE GÁN NHÃN V4.0 (CONTEXT-AWARE)** được trình bày chuẩn Markdown, tối ưu hóa để bạn copy thẳng vào **Obsidian**.

Tôi đã tích hợp toàn bộ các quy tắc xử lý "Reply to Hate" (Phản đòn), "Criticizing Bad Behavior" (Lên án hành vi xấu) và cách xử lý Emoji/Teencode mà chúng ta đã thảo luận.

(Copy từ dòng dưới)

🏷️ GUIDELINE GÁN NHÃN DỮ LIỆU: TOXIC & HATE SPEECH (V4.0)

> ⓘ **Thông tin dự án**
>
> - **Mô hình:** PhoBERT (Context-Aware Input).
> - **Đầu vào:** `Tiêu đề bài viết (Context)` + `Nội dung bình luận (Text)`.
> - **Mục tiêu:** Phân loại dựa trên **Ngữ cảnh** và **Ý định** thực sự của người viết.

---

1. NGUYÊN TẮC CỐT LÕI: "CONTEXT IS KING" 👑

Khác với các phiên bản trước, chúng ta KHÔNG đánh giá bình luận một cách độc lập.

Công thức:

$$Label = f(\text{Tiêu đề} + \text{Bình luận})$$

- **Tại sao?** Một từ có thể là bình thường ở ngữ cảnh này nhưng là Hate Speech ở ngữ cảnh khác.
- **Quy tắc:** Đọc Tiêu đề trước $\rightarrow$ Xác định chủ đề (LGBT, Vùng miền, Tai nạn...) $\rightarrow$ Đọc bình luận $\rightarrow$ Gán nhãn.

---

2. ĐỊNH NGHĨA NHÃN (LABELS)

🟢 Nhãn 0: CLEAN (Sạch / An toàn / Hợp lý)

Bình luận không chứa yếu tố độc hại, hoặc là phản ứng xã hội chấp nhận được.

- ✅ **Khen ngợi, hỏi đáp, chia sẻ** lịch sự.
- ✅ **Góp ý/Chê bai** sản phẩm nhưng không dùng từ tục tĩu (VD: "Nhạc dở quá").
- ✅ **Quan trọng: LÊN ÁN CÁI XẤU (Criticizing Bad Behavior):**
  - Chửi kẻ vi phạm pháp luật, kẻ phản động, kẻ sống lỗi (ngoại tình, vứt rác, chửi cha mẹ).
  - *Ví dụ:* "Thằng này mất dạy quá, tống cổ nó đi tù" (Context: Bài viết về kẻ đánh cựu chiến binh) → **Label 0**.
- ✅ **Quan trọng: BÊNH VỰC/PHẢN BÁC (Defense):**
  - Chửi lại những kẻ kỳ thị (Antifan) để bảo vệ lẽ phải.
  - *Ví dụ:* "Thời đại nào rồi còn kỳ thị, đầu óc thiển cận" → **Label 0**.

🟡 Nhãn 1: OFFENSIVE (Thô lỗ / Xúc phạm chung / Tục tĩu)

Có yếu tố tiêu cực, thô tục nhưng **KHÔNG** nhắm vào đặc điểm được bảo vệ (Giới tính, Vùng miền, Tôn giáo...).

- ⚠️ **Chửi thề vô cớ (Profanity):** "Đm chán đời", "Vãi lồn", "Như cứt".
- ⚠️ **Xúc phạm cá nhân (Personal Insult):** Chửi 1 cá nhân cụ thể (không phải vì họ là LGBT/Bắc kỳ mà vì ghét cá nhân đó).
  - *Ví dụ:* "Con điên này nói nhiều quá", "Thằng admin ngu như bò".
- ⚠️ **Gây hấn trong tranh luận:** Dùng từ ngữ thô tục để cãi nhau (nhưng không kỳ thị).
- ⚠️ **Slang/Sexual Innuendo:** Nói bậy, nói lái về tình dục nhưng không tấn công. (VD: "Đấu kiếm", "Thông ass" - nếu mang tính đùa cợt thô tục).

🔴 Nhãn 2: HATE SPEECH (Thù ghét & Nguy hiểm)

Tấn công, đe dọa, hạ thấp nhân phẩm dựa trên **BẢN SẮC** của nhóm người (Identity).

> ⚡ **Các Topic nhạy cảm cần bật chế độ "Red Alert":**
>
> 1. **Gender (LGBT):** Đồng tính, chuyển giới.
> 2. **Region (Vùng miền):** Bắc kỳ, Nam kỳ, TNT...
> 3. **Body (Ngoại hình):** Béo, gầy, khuyết tật.
> 4. **Violence (Bạo lực):** Kêu gọi giết, trù ẻo chết chóc.

- ⛔ **Từ khóa định danh (Explicit):** "Bọn bê đê", "Lũ bắc kỳ chó", "Thằng khuyết tật".
- ⛔ **Ngữ cảnh ép buộc (Implicit):**
  - Context: Đám cưới LGBT 🏳️‍🌈.
  - Comment: "Tởm lợm", "Bệnh hoạn", "Nhục nhã dòng họ", "Vô phúc".

- → **Label 2** (Dù không có chữ "gay", nhưng ngữ cảnh ám chỉ sự ghê tởm với bản dạng giới).
- ⛔ **Vơ đũa cả nắm (Stereotyping):** "99% dân đi xe này là óc chó", "Dân ở đây toàn trộm cắp".

---

3. CHECKLIST XỬ LÝ "TRƯỜNG HỢP KHÓ" (EDGE CASES)

> 🔥 **Quy tắc "Thấy gì gán đó"**
>
> Đừng suy diễn quá xa. Hãy gán nhãn dựa trên từ ngữ và thái độ hiển thị trong văn bản.

🛡️ Case A: "Chửi lại kẻ xấu" (Reply to Hate)

- **Tình huống:** A chửi Bê đê. B chửi A là "Thằng ngu".
- **Xử lý:** Gán cho B là **Label 0** (hoặc Label 1 nếu B chửi quá tục: "Địt mẹ thằng ngu").
- **Tuyệt đối KHÔNG gán Label 2** cho B. Vì B đang tấn công kẻ kỳ thị, không tấn công nhóm yếu thế.

🛡️ Case B: "Lên án hành vi sai trái" (Criticizing Actions)

- **Tình huống:** Bài viết về thanh niên nẹt pô, vượt đèn đỏ, đánh người già.
- **Comment:** "Lũ súc vật", "Cặn bã xã hội", "Chết bớt cho sạch đất".
- **Xử lý:**
  - "Lũ súc vật": **Label 0/1** (Chửi hành vi).
  - "Chết bớt cho sạch đất": **Label 2** (Topic Violence - Kích động chết chóc/Trù ẻo). *Lưu ý: Nếu chỉ chửi "ngu/mất dạy" thì là 0. Nếu trù ẻo "chết đi" thì là 2.*

🛡️ Case C: "Ẩn ý thâm nho" (Passive Aggressive)

- **Tình huống:** Bài viết về LGBT.
- **Comment:** "Thương bố mẹ em", "Bố mẹ ở nhà chắc buồn lắm", "Nhục nhã gia phong".
- **Xử lý: Label 2**. Đây là văn mẫu điển hình của Hate Speech tại VN (dùng đạo đức giả để phủ nhận sự tồn tại của LGBT).

🛡️ Case D: Teencode & Emoji

- **Teencode:** `paki` = `bắc kỳ`, `bede` = `bê đê`. Coi như từ chuẩn.
- **Emoji:**
  - 🏳️‍🌈, 🌈 = Tín hiệu nhận biết Topic Gender.

- 😖, 🤢 = Tín hiệu của sự ghê tởm (Hate/Offensive).
- 🤡 = Tín hiệu của sự mỉa mai/chế giễu.

---

4. BẢNG ĐỐI CHIẾU NHANH (QUICK LOOKUP)

Context (Tiêu đề)	Comment	Label	Lý do
Đám cưới LGBT 🏳️‍🌈	"Nhìn tởm quá"	**2**	Hate Speech (Topic Gender).
Món ăn côn trùng	"Nhìn tởm quá"	**1**	Offensive (Chê bai ghê rợn, ko phải hate).
Vụ án đánh người	"Thằng này mất dạy thật"	**0**	Clean (Lên án cái xấu hợp lý).
Bất kỳ	"Đm cuộc đời chán vcl"	**1**	Offensive (Chửi thề cảm thán).
Đám cưới LGBT 🏳️‍🌈	"Bọn này làm mất mặt đàn ông"	**2**	Hate Speech (Định kiến giới).
Đám cưới LGBT 🏳️‍🌈	"Ai chửi họ là đồ vô học"	**0**	Clean (Bênh vực/Phản bác).
Tai nạn giao thông	"Chết mẹ mày đi đồ ngu"	**2**	Hate Speech (Topic Violence - Trù ẻo).
Clip hài/Prank	"Mày bị khùng hả"	**1**	Offensive (Xúc phạm cá nhân/Đùa cợt).

🖊 Ghi chú cuối cùng

Nếu gặp trường hợp quá khó phân định giữa 1 và 2: Hãy tự hỏi "Comment này có khiến một nhóm người (dựa trên giới tính/vùng miền) cảm thấy bị đe dọa hoặc tổn thương không?"

- Có → **Label 2**.
- Không (chỉ cá nhân thấy khó chịu) → **Label 1**.