SafeSense-VI

Khai thác đặc trưng ngữ cảnh và mô hình PhoBERT-base-v2 trong bài toán phân loại đa tầng ngôn ngữ độc hại tiếng Việt.

Nhóm: F35

1. Trần Thanh Thiện
2. Nguyễn Đan Huy

Giải mã Ngữ cảnh - Bảo vệ không gian số Việt"

Competition: IT Got Talent 2025

Mục lục

1. **Tổng quan & Lý do chọn đề tài**
2. **Công nghệ sử dụng.**
3. **Nội dung chính & điểm nổi bật**
4. **Kết quả & Chứng minh**

1. Tổng quan & lý do chọn đề tài

Thực trạng:

NGƯỜI DÙNG MXH (2024)

77.9 Triệu (~78% dân số)

Tiếp cận Hate Speech

78% (Theo báo cáo VPIS)

Bộ lọc hiện nay

Thiếu công cụ tự động phát hiện hiệu quả

Vấn đề các nền tảng đang gặp phải

Facebook, YouTube gặp khó khăn kiểm duyệt tiếng Việt

1.000+ Biến thể Teencode

Ngôn ngữ liên tục **"tiến hóa"** để vượt qua các bộ lọc từ khóa truyền thống (Keyword-based)

n.g.u | ch3t | ô kề | đ.m | vcll | ko

→ *Khiến AI quốc tế "mù mờ" trước các biến thể bypass.*

Sự mơ hồ của Ngữ cảnh

Cùng một từ ngữ mang ý nghĩa trái ngược dựa trên **ý định người dùng**.

"Vụ đó bị **tử hình** rồi" CLEAN

(Tin tức / Tường thuật khách quan)

"thằng này **tử hình** nó đi" HATE

(Đe dọa / Công kích cá nhân)

→ Mô hình quốc tế thường chặn nhầm vì thiếu bối cảnh văn hóa.

Kết luận: **Sự cấp thiết của một công cụ phát hiện tự động.**

🌟 Lý do chọn đề tài

1. Tác động xã hội lớn:

- Bảo vệ người dùng mạng xã hội Việt Nam
- Giảm thiểu hate speech, harassment
- Tạo môi trường internet lành mạnh

2. Thách thức kỹ thuật cao:

- NLP tiếng Việt phức tạp (positive slang, context-dependent)
- Ranh giới mờ giữa các nhãn
- Cần innovation để giải quyết

3. Ứng dụng thực tế rõ ràng:

- Facebook, YouTube, TikTok moderation
- Forum, comment filtering
- Real-time detection (<100ms)

4. Thiếu giải pháp chất lượng:

- Chưa có dataset tiếng Việt chất lượng cao
- Chưa có guideline khoa học cho gán nhãn
- Chưa có model hiểu được nuance

CÔNG NGHỆ SỬ DỤNG

🤖 **Model: PhoBERT-v2**

Base Model:

Name: vinai/phobert-base-v2

Type: RoBERTa-base for Vietnamese

Parameters: 135M

Training: 20GB Vietnamese text

Max length: 256 tokens

Tokenizer: BPE với word segmentation

Tại sao chọn PhoBERT-v2?

- SOTA for Vietnamese NLP tasks
- Pre-trained on large, diverse Vietnamese corpus
- Proven stability & performance
- Active community & support
- Production-ready

Bài toán cần giải quyết

Guideline V7.2: Triết lý: Ngữ cảnh quyết định Nhãn (Contextual Intelligence)

CLEAN

An toàn & Văn minh

Tường thuật: "Vụ đó bị tử hình rồi"

Cảnh báo: "Coi chừng nó giết đấy"

Khen ngợi: "Giỏi vcl", "Đỉnh vãi"

OFFENSIVE

Phản cảm & Công kích

Chửi thề tiêu cực: "đm chán thật", "Ngu vcl"

Công kích cá nhân: "Mày nín đi", "Thằng này nên đi tù"

Miệt thị nhẹ: "Xấu quá", "Ngu như..."

HATE SPEECH

Thù ghét & nguy hiểm

Family Attack: "Ba mẹ mày ngu nên..."

Kích động: "Xiên chết nó đi"

Identity Hate: "Bắc kỳ...", "LGBT bệnh hoạn"

Hệ thống gán nhãn xử lý hơn **30 trường hợp "vùng xám"** dựa trên Cây quyết định (Decision Tree) dày 50 trang

2. Quá trình xử lý dữ liệu

Dữ liệu thô: 38,000 comments(facebook & youtube)

Quy mô: 7,626 mẫu gán nhãn thủ công.

Độ tin cậy: Chỉ số Cohen's Kappa > 0.7

Phân phối nhãn thực tế:

- Clean (Sạch): 44.6%.
- Offensive (Phản cảm): 26.6%.
- Hate (Thù ghét): 28.8%.

Nguồn: 38k bình luận từ Facebook và YouTube (Showbiz, LGBT, Drama...).

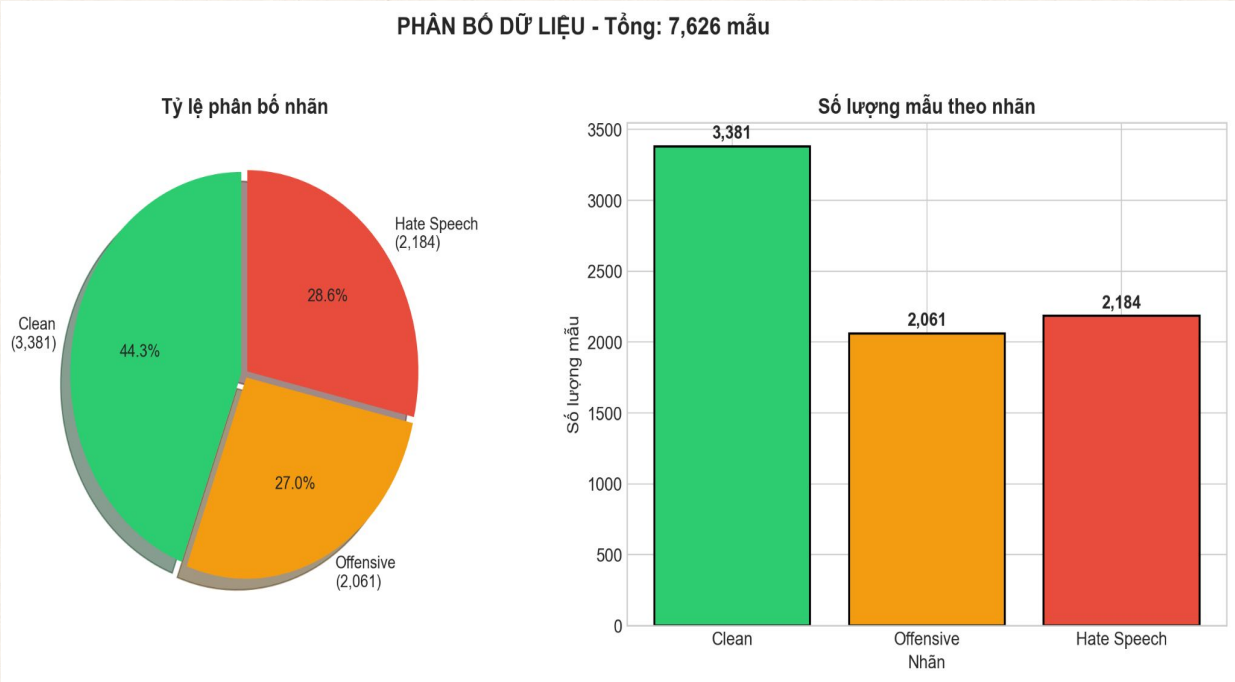

2. Quá trình xử lý dữ liệu

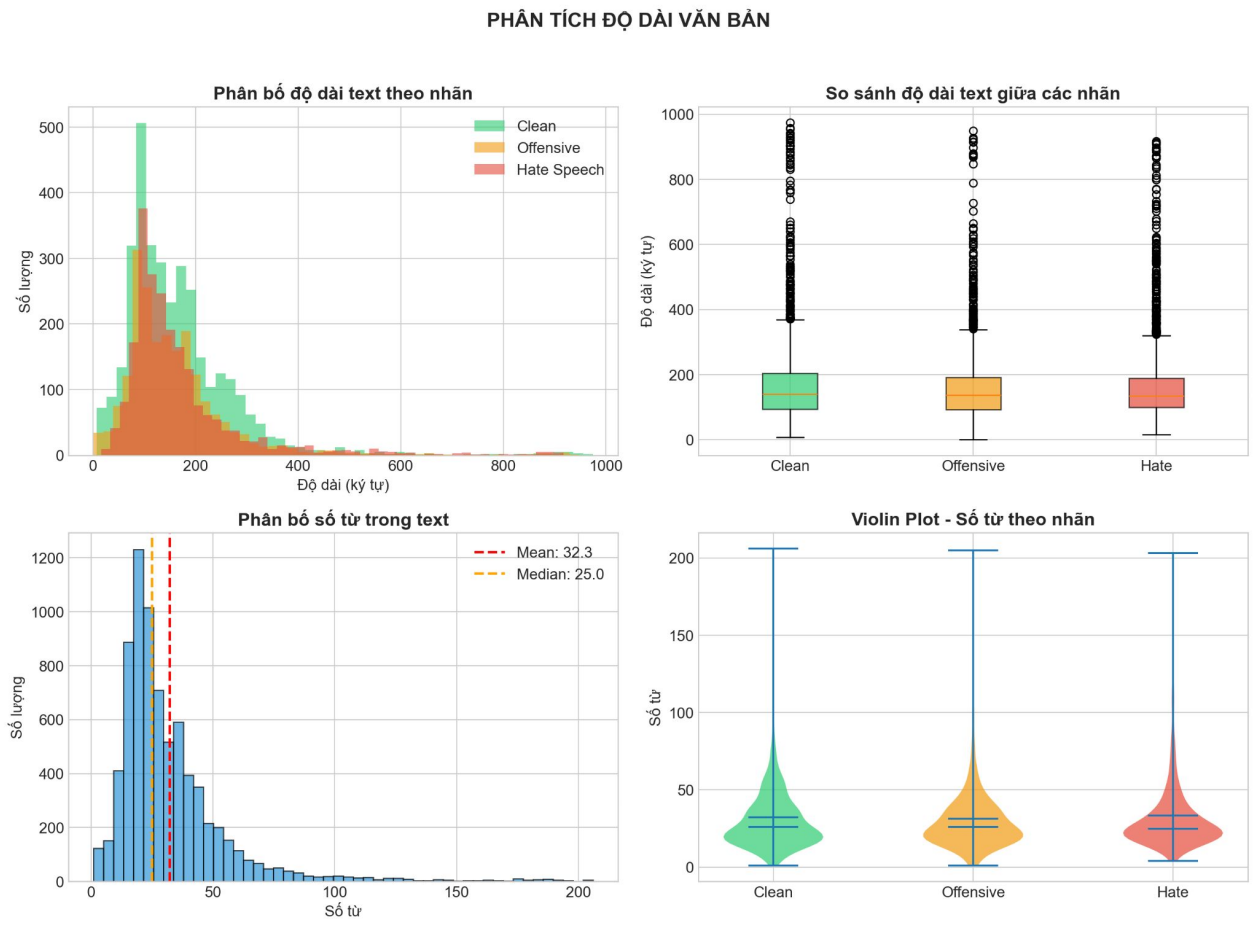

2. Quá trình xử lý dữ liệu

Tiền xử lý nâng cao 18 bước - Pipeline 5 nhóm chính

> "Bảo toàn nồng độ + Bảo toàn cấu trúc" (Intensity + Structure Preservation)

Điểm nhấn kỹ thuật:

- ⭐ 50+ họ phổ biến Việt Nam: Nguyễn, Trần, Lê, Phạm, Hoàng...
- ⭐ 63 tỉnh thành + địa danh: Bảo vệ khỏi bị nhầm với tên người
- ⭐ Intensity-sensitive words: Giữ nguyên "đm", "vcl" để model học gradient
- ⭐ Context-aware: Phân biệt "m" = "em" hay "mày" theo ngữ cảnh

2. Quá trình xử lý dữ liệu

Tại sao phải làm việc này ?

1. Intensity & Pattern (Nhóm 2, 4)

- Bảo toàn "đm", "vcl" để học cường độ cảm xúc.
- Xử lý Bypass: n.g.u → ngu, Leetspeak: ch3t → chết.

2. Special Token Protection PRIVACY POLICY

- <person>, <user>: Bảo vệ quyền riêng tư & tránh học vẹt tên riêng.
- <emo_pos>, <emo_neg>, <eng_insult>: Giữ tín hiệu cảm xúc tập trung.

3**. Context-Aware (Nhóm 5)**

- Phân biệt "m" (em) vs "m" (mày) dựa vào ngữ cảnh.
- Sử dụng </s> tách Title và Comment để mô hình hiểu bối cảnh post.

2. Quá trình xử lý dữ liệu

Ví dụ điển hình

Áp dụng triết lý Guideline V7.2: Ngữ cảnh quyết định Nhãn

"giỏi vcl"	**Nhãn 0**	Ngoại lệ từ lóng tích cực
"nên vào tù"	**Nhãn 0**	Phẫn nộ văn minh (Reporting)
"thằng này ngu"	**Nhãn 1**	Đại từ kích động (Pronoun Trigger)
"đúng thằng óc chó"	**Nhãn 2**	Hạ thấp nhân phẩm (Dehumanization)
"nên bắn bỏ thằng ..."	**Nhãn 2**	Kích động bạo lực (Violence Incitement)

2. Quá trình xử lý dữ liệu

Lựa chọn chuẩn hóa

Danh mục	Ví dụ	Hành động	Lý do
Teencode Trung tính	"ko" → "không"	✅ CHUẨN HÓA	Không mất nghĩa
	"ak" → "ạ"	✅ CHUẨN HÓA	Tránh lỗi NER
	"mik" → "mình"	✅ CHUẨN HÓA	Từ chuẩn
Nhạy cảm Cường độ	"đm"	❌ GIỮ NGUYÊN	Cường độ nhẹ
	"địt mẹ"	❌ GIỮ NGUYÊN	Cường độ cao
	"vcl"	❌ GIỮ NGUYÊN	Dấu hiệu tiếng lóng
	"vãi lồn"	❌ GIỮ NGUYÊN	Dạng tục tĩu

2. Quá trình xử lý dữ liệu

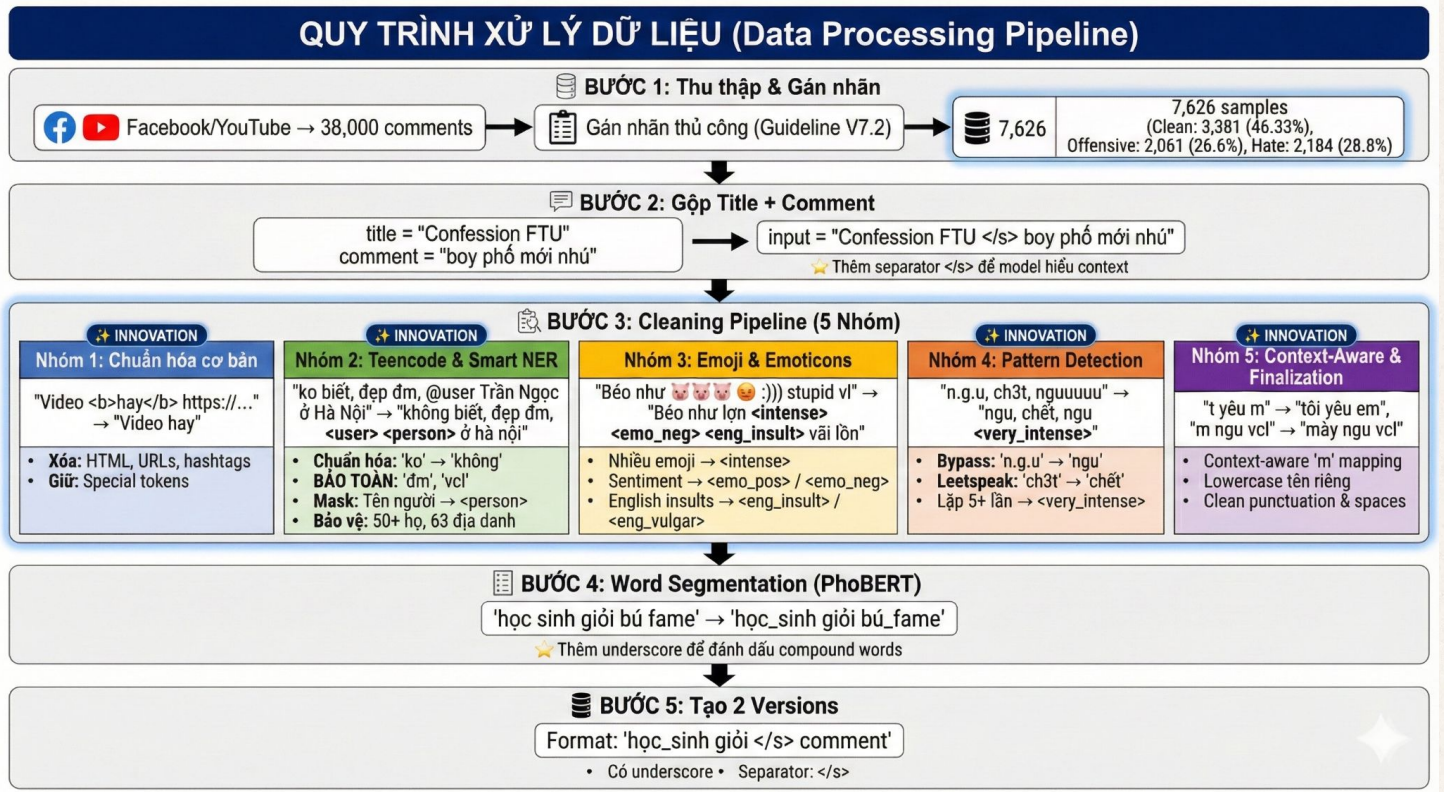

Chi tiết quy trình xử lý dữ liệu

4. Kết quả đạt được

KẾT QUẢ ĐÁNH GIÁ TRÊN TẬP TEST ĐỘC LẬP (763 MẪU)

Các chỉ số chính:

- **Accuracy: 80.87%**
- **F1-Macro: 79.95%**
- **F1 Nhãn Hate (Lớp nguy hiểm nhất): 81.69%**

Mô hình được lựa chọn dựa trên Best Validation F1 tại Epoch 4 (0.7960) và kiểm định lại trên tập Test độc lập để đảm bảo tính khách quan.

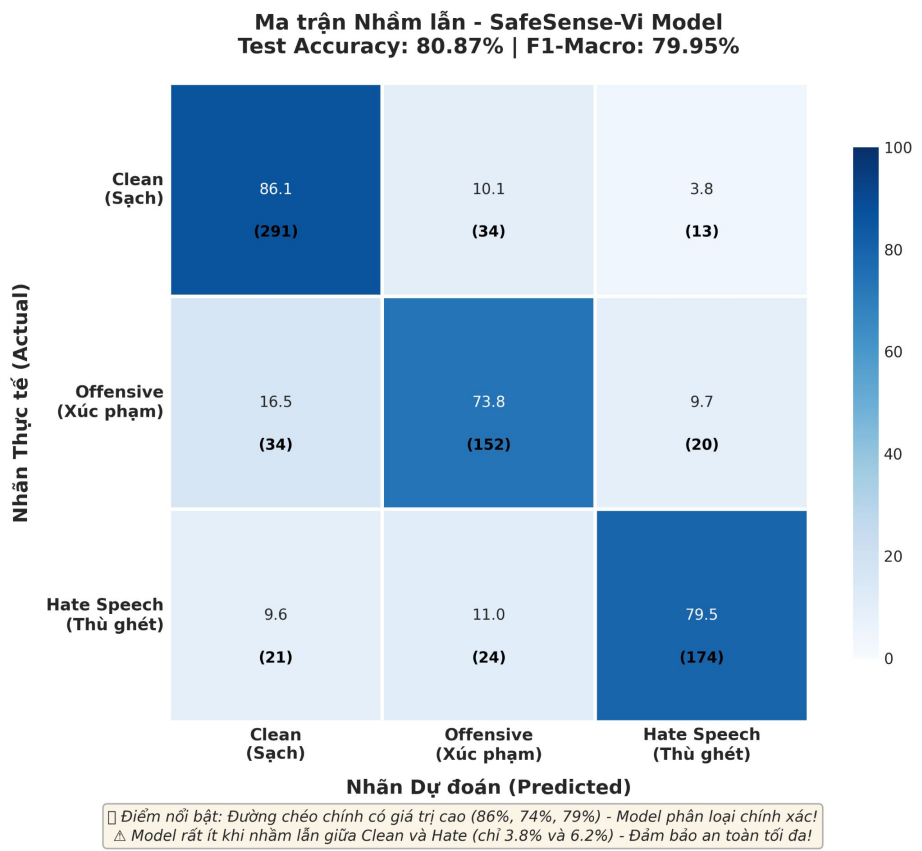

4. Kết quả đạt được

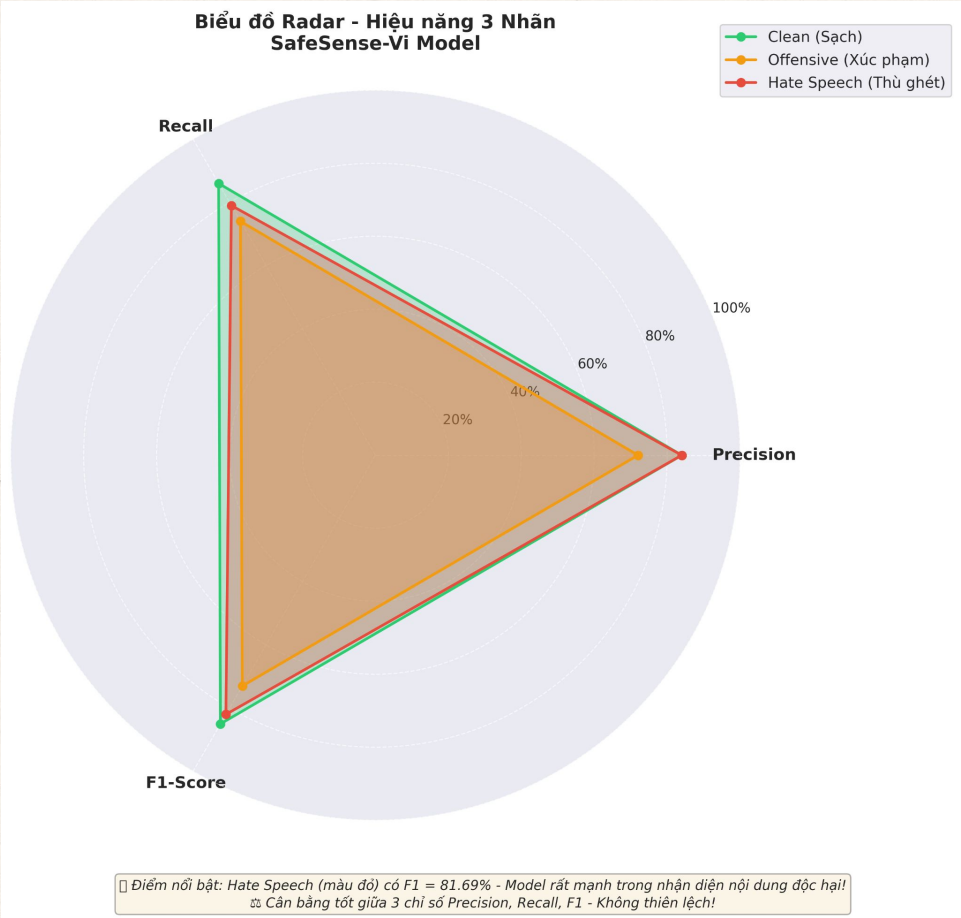

4. Kết quả đạt được

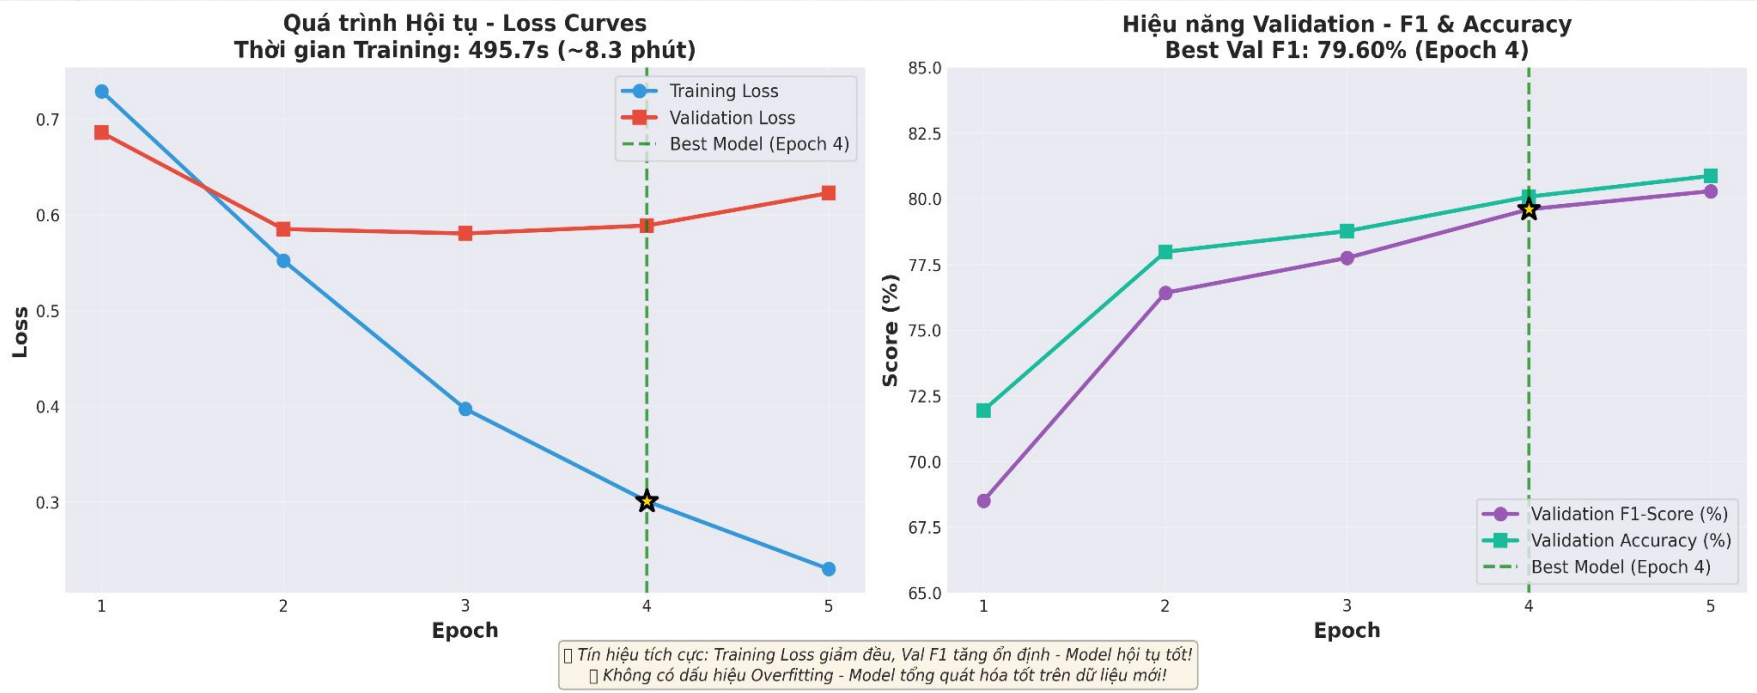

4. Demo